

Projet Global : Data Science, Détection de Fraude, Segmentation Client et MLOps

Contexte général

Dans le cadre de ce projet, vous interviendrez en tant que Data Scientist au sein d'une entreprise financière et marketing souhaitant exploiter ses données pour :

- détecter automatiquement les transactions frauduleuses ;
- mieux comprendre les comportements clients ;
- segmenter intelligemment les clients ;
- et industrialiser les modèles grâce à une approche MLOps.

Le projet sera divisé en deux exercices complémentaires couvrant :

- le Machine Learning supervisé,
- le Clustering non supervisé,
- la Data Visualisation,
- l'interprétation métier,
- et les principes du MLOps.

Exercice 1 — Détection de fraude bancaire avec Machine Learning

Objectif

L'objectif est de développer un système intelligent capable de détecter automatiquement les transactions frauduleuses à partir de données financières.

Données disponibles

Variables

Variable	Description
step	Unité temporelle de la transaction
type	Type de transaction (PAYMENT, TRANSFER, CASH_OUT, etc.)
amount	Montant transféré
nameOrig	Identifiant du client émetteur
oldbalanceOrg	Solde avant transaction
newbalanceOrig	Solde après transaction
nameDest	Identifiant du destinataire
oldbalanceDest	Solde destinataire avant transaction
newbalanceDest	Solde destinataire après transaction
isFraud	Variable cible indiquant si la transaction est frauduleuse
isFlaggedFraud	Indique si la transaction a été signalée automatiquement

Variable cible

isFraud

Valeur	Signification
--------	---------------

0	Transaction normale
1	Transaction frauduleuse

Travail demandé

1. Analyse exploratoire des données

- étude des transactions ;
- analyse des montants ;
- étude des comportements suspects ;
- visualisations.

2. Prétraitement

- gestion des valeurs manquantes ;
- encodage ;
- normalisation ;
- gestion du déséquilibre des classes.

3. Modélisation

Tester plusieurs modèles :

- Régression Logistique,
- Random Forest,
- XGBoost,
- LightGBM,
- Réseaux de neurones.

4. Évaluation

Métriques :

- Accuracy,
- Precision,
- Recall,
- F1-score,
- ROC-AUC.

5. Interprétabilité

- importance des variables ;
- SHAP ;
- analyse des faux positifs/faux négatifs.

Exercice 2 — Segmentation intelligente des clients avec Clustering

Objectif

L'objectif est d'identifier automatiquement différents profils de clients afin d'améliorer les campagnes marketing et les stratégies de fidélisation.

Données disponibles

Variables démographiques

Variable	Description
Year_Birth	Année de naissance

Variable	Description
Education	Niveau d'éducation
Marital_Status	Situation matrimoniale
Income	Revenu annuel
Kidhome	Nombre d'enfants
Teenhome	Nombre d'adolescents

Variables comportementales

Variable	Description
Recency	Nombre de jours depuis le dernier achat
MntWines	Dépenses en vins
MntFruits	Dépenses en fruits
MntMeatProducts	Dépenses en viande
MntFishProducts	Dépenses en poisson
MntSweetProducts	Dépenses en produits sucrés
MntGoldProds	Dépenses en produits premium

Variables liées aux canaux d'achat

Variable	Description
NumDealsPurchases	Achats promotionnels
NumWebPurchases	Achats web
NumCatalogPurchases	Achats catalogue
NumStorePurchases	Achats magasin
NumWebVisitsMonth	Visites web mensuelles

Variables marketing

Variable	Description
AcceptedCmp1-5	Réponse aux campagnes précédentes
Response	Réponse à la dernière campagne
Complain	Réclamation client

Travail demandé

1. Analyse exploratoire

- profils clients ;
- comportements d'achat ;
- analyse des revenus ;
- visualisations avancées.

2. Prétraitement

- encodage ;
- normalisation ;
- gestion des valeurs manquantes ;
- PCA éventuelle.

3. Clustering

Tester :

- K-Means,
- DBSCAN,
- Agglomerative Clustering,
- Gaussian Mixture Models.

4. Évaluation des clusters

- Silhouette Score,
- Elbow Method,
- Davies-Bouldin Score.

5. Interprétation métier

Identifier différents profils :

- clients premium,
- clients digitaux,
- clients sensibles aux promotions,

- clients dormants.

6. Recommandations business

- fidélisation ;
 - campagnes marketing ;
 - personnalisation.
-

Partie commune — MLOps

Pour les deux exercices, une réflexion MLOps est attendue.

Éléments attendus

1. Pipeline de données

- ingestion ;
- validation ;
- nettoyage automatique.

2. Versionning

- données ;
- modèles ;
- paramètres.

3. Déploiement

Proposition d'architecture :

- Flask/FastAPI,

- Dash/Streamlit,
- Docker.

4. Monitoring

- suivi des performances ;
- dérive des données ;
- stabilité des modèles/clusters.

5. CI/CD

Présentation simplifiée :

- GitHub/GitLab,
- automatisation,
- déploiement continu.

Livrables attendus

Chaque groupe devra fournir :

- notebooks bien structurés ;
- analyses détaillées ;
- visualisations professionnelles ;
- rapport technique ;
- interprétation métier ;
- architecture MLOps ;

- dashboard interactif ;
 - présentation finale.
-

IMPORTANT — Qualité du code et GitHub

Une attention particulière sera portée à :

- la qualité du code ;
- la lisibilité ;
- l'organisation du projet ;
- les commentaires ;
- la documentation ;
- et la structuration GitHub.

Un dépôt GitHub propre et professionnel est obligatoire.

Le dépôt devra contenir :

- un README.md clair ;
 - des notebooks commentés ;
 - une structure organisée ;
 - les dépendances (requirements.txt) ;
 - des explications sur l'exécution du projet ;
 - les résultats et interprétations.
-

Compétences développées

Ce projet permettra de travailler sur :

- Data Science,
- Machine Learning supervisé,
- Clustering,
- Détection de fraude,
- Segmentation client,
- Data Visualisation,
- MLOps,
- Déploiement IA,
- Architecture analytique,
- Git/GitHub professionnelle